

# Derin Öğrenme Mimarileri Kullanılarak Geri Dönüşüm Otomasyonu İçin Görüntü Tabanlı Atık Sınıflandırma Analizi

Mehmet Yağlı<sup>1\*</sup>, Furkan Darakçılar<sup>1</sup>, Murat Eren Zoroğlu<sup>1</sup>

<sup>1</sup>Dept. of Computer Engineering, Sivas Cumhuriyet University, Turkey

\*(yagli.my@gmail.com)

**Özet** – Bu çalışmada, evsel atıkların kaynağında ayrıştırılmasını optimize etmek amacıyla derin öğrenme tabanlı bir sınıflandırma analizi gerçekleştirilmiştir. Çalışma kapsamında, Kaggle platformunda sunulan ve altı farklı atık sınıfını (cam, kağıt, karton, plastik, metal ve çöp) içeren yaklaşık 2500 görüntüden oluşan veri seti kullanılmıştır. Atıkların karmaşık fiziksel deformasyonları ve bant üzerindeki heterojen yapıları, geleneksel ayrıştırma yöntemlerini yetersiz kılmaktadır. Bu zorlukları aşmak için öncelikle hafif sıklet bir model olan MobileNetV2 ile temel bir sınıflandırma gerçekleştirilmiş, ardından sistemin doku ve form analizi yeteneğini artırmak amacıyla yüksek kapasiteli EfficientNetB3 mimarisine geçiş yapılmıştır. Eğitim süreçlerinde, modelin aşırı öğrenmesini ve yıkıcı unutma problemini engellemek adına toplu normalizasyon katmanlarının dondurulduğu güvenli ince ayar (safe fine-tuning) stratejisi uygulanmıştır. Elde edilen deneysel sonuçlar, önerilen EfficientNetB3 tabanlı sistemin 0.952 genel doğruluk oranına ulaştığını ve endüstriyel geri dönüşüm standartlarında uygulanabilir bir performans sergilediğini ortaya koymuştur.

*Anahtar Kelimeler – Derin Öğrenme, EfficientNetB3, Atık Sınıflandırma,, Geri Dönüşüm Otomasyonu, Bilgisayarlı Görü*

## 1. GİRİŞ

Atıkların kaynağında tespiti ve ayrıştırılması, çevresel sürdürülebilirlik ve doğal kaynakların korunması açısından hayati bir öneme sahiptir. Karışık atıkların erken tespiti, geri dönüşüm tesislerinin zamanında müdahale etmesine ve malzeme saflığının korunmasına olanak tanır. Ayrıca atıkların türlerine göre otomatik tespiti, geri dönüştürülebilir malzemelerin israf edilmesi durumunda erken uyarı ve düzeltici tedbirlerin alınmasını sağlar. Bu, çevresel tahribatın önlenmesine veya etkilerinin en aza indirilmesine yardımcı olabilir. Ayrıca, atıkların tespiti, döngüsel ekonomi modelinde verimliliğin korunması için önemlidir. Yanlış sınıflandırılmış atıkların üretim hatlarına girmesi, maliyetli hasarlara ve hatta tesis duruşlarına yol açabilir. Dolayısıyla, atıkların doğru tespiti, çevresel istikrarın sağlanması açısından da kritik bir rol oynar.

Şu anda, atıkların tespiti konusunda çeşitli kısıtlamalar bulunmaktadır. Bunlar teknik, ekonomik ve stratejik faktörlerden kaynaklanmaktadır. Teknik olarak, bazı atık türleri karmaşık fiziksel deformasyonlara uğramıştır ve görsel özelliklerini tespit etmeyi zorlaştıran çevresel faktörlere maruz kalmışlardır. Bu durum, geri dönüştürülebilir atıkların tespit edilmesini zorlaştırabilir ve otomasyon sistemlerinin etkinliğini azaltabilir. Ayrıca, ekonomik kısıtlamalar da atıkların tespitini etkileyebilir. Birçok tesis, kendi ayrıştırma süreçlerini iyileştirmek için optik ve sensör tabanlı tespit sistemlerini kullanırken, bu tür maliyetli donanımları tüm hatlarda gerçekleştirebilecek bütçeye sahip olmayabilir. Son olarak, stratejik kısıtlamalar da atıkların tespitini etkileyebilir. Bazı bölgeler, manuel iş gücüne dayalı geleneksel ayrıştırma eylemlerini istihdam nedenleriyle göz ardı etmek veya tolere etmek isteyebilir.

Bu kısıtlamalara rağmen, atıkların tespiti konusundaki teknolojik gelişmeler devam etmektedir. Yeni optik sensör sistemleri, bant izleme teknolojileri ve yapay zeka destekli tespit sistemleri, atıkları tespit etme kabiliyetini artırmak için sürekli olarak geliştirilmektedir. Yapay zeka, nesne tespiti ve sınıflandırma alanında son yıllarda önemli ilerlemeler kaydetmiştir. Özellikle evrişimli sinir ağları gibi yenilikçi nesne tespit modelleri, bir görüntünün piksellerinden hiyerarşik özellikler çıkarır ve her bir nesnenin olasılıklarını tahmin eder. Bu yöntem, geleneksel makine öğrenmesi modellerinden daha kararlı çalışır ve karmaşık arka planlarda daha yüksek başarı gösterir.

Mevcut kısıtlamaları aşmak ve bu modellerin daha da geliştirilmesi, çevresel sürdürülebilirlik açısından kritik olan atık tespiti için daha etkin bir araç olmalarını sağlamak için birçok araştırma yapılmıştır. Bircanoğlu ve diğerleri, evsel atıkların sınıflandırılması için RecycleNet isimli bir yöntem önermişlerdir. Bu yöntemde, ResNet omurga ağı olarak kullanılırken, atık nesnelerini tespit ederken model performansını artırmak için optimize edilmiştir [1]. Bir diğer çalışmada ise Zheng, çöp tespiti için YOLOv5 nesne algılama algoritmasını temel alan bir yöntem önermektedir. Bu yöntemde, YOLOv5 iyileştirilerek atık sınıflandırma sistemi önerilmiş ve gerçek zamanlı tespiti başarıyla gerçekleştirmiştir [2]. Atıkların tespiti alanında yapılan bir diğer çalışmada ise, sınırlı donanım kaynaklarında sınıflandırma yapmak için derin öğrenme tabanlı bir sistem önermektedir. Liu ve He, sistemlerinde evrişimli sinir ağlarını kullanarak eğitim ve test aşamalarında yüksek doğruluk oranlarına ulaştıklarını göstermektedir [3].

Bu çalışma kapsamında 6 tip atığın tespit edilerek sınıflandırılması hedeflenmiştir. Mevcut nesne tespiti teknolojilerinin heterojen atık yapıları karşısında yaşadığı kısıtlamaları aşmak amacıyla, öncelikle MobileNetV2 gibi hafif mimarilerin kapasite sınırları analiz edilmiştir. Ardından doku analizi konusunda daha üstün olan EfficientNetB3 mimarisine geçiş yapılmıştır. Çalışmamızın en önemli katkısı, modelin eğitim sürecinde eski öğrendiklerini unutmasını engellemek adına toplu normalizasyon katmanlarının dondurulduğu güvenli ince ayar (safe fine-tuning) stratejisinin uygulanması ve bu sayede 0.952 gibi yüksek bir doğruluk oranına ulaşılmasıdır.

## II. MATERYAL VE YÖNTEM

Çalışmanın bu bölümünde, atık sınıflandırma sürecinde kullanılan görsel veri seti ve nesne tespiti için tercih edilen derin öğrenme yöntemleri ayrıntılı olarak açıklanmıştır.

### A. Veri Seti

Atıkların tespitini yapabilmek için altı sınıflı görsel veri seti kullanılmıştır. Veri seti Kaggle platformu üzerinde açık kaynak olarak sunulmaktadır [4]. Veri seti içerisinde karton, cam, metal, kağıt, plastik ve çöp sınıflarına ait, farklı açılardan ve çeşitli arka plan koşullarında çekilmiş görüntüler yer almaktadır. Toplamda yaklaşık 2500 görsel veri barındıran bu set, derin öğrenme modellerinin eğitimi ve test edilmesi süreçlerinde kullanılmıştır. Ağın aşırı öğrenmesini engellemek ve karmaşık çevre koşullarına karşı toleransını artırmak amacıyla, eğitim görselleri üzerinde döndürme, yakınlaştırma ve kontrast değişimleri gibi veri artırma (data augmentation) teknikleri uygulanmıştır.

### B. Yöntem

Nesne tespiti ve sınıflandırma, bilgisayarlı görmenin en önemli alanlarından biridir ve derin öğrenme temelli evrişimli sinir ağları, bu alanda öne çıkan algoritmalar. Bu ağların en büyük avantajı, görüntülerden otomatik olarak hiyerarşik özellik çıkarımı yapabilmesidir. Bu sayede karmaşık desenleri öğrenebilir ve nesneleri arka plandan başarılı bir şekilde ayırabilirler. Bu çalışmada, nesne tespiti için aktarım öğrenmesi (transfer learning) yaklaşımı benimsenmiş ve iki farklı evrişimli sinir ağı mimarisi analiz edilmiştir.

İlk aşamada, düşük parametre sayısı ile hızlı işlem yapabilen MobileNetV2 mimarisi kullanılarak temel bir sınıflandırma çerçevesi oluşturulmuştur. Ancak atıkların şeffaflık, yansıma ve ezilmiş dokular gibi heterojen özelliklerini daha yüksek hassasiyetle analiz edebilmek için ikinci aşamada EfficientNetB3 mimarisine geçiş yapılmıştır. EfficientNet, ağın derinliğini, genişliğini ve çözünürlüğünü birleşik bir katsayı ile orantılı olarak ölçeklendiren yapısı sayesinde yüksek özellik çıkarım verimliliği sunmaktadır.

Her iki modelin ağ yapısında, özellik çıkarım katmanlarının ardından genel ortalama ortaklama (global average pooling) ve modelin kararlılığını artırmak için toplu normalizasyon (batch normalization) katmanları kullanılmıştır. Eğitim sürecinin optimizasyonunda, modelin önceden öğrendiği ağırlıkları unutmasını (yıkıcı unutma) engellemek amacıyla, toplu normalizasyon katmanlarının ağırlıkları dondurularak güvenli ince ayar (safe fine-tuning) stratejisi uygulanmıştır. Ağın son katmanlarında tam bağlantılı yapılar kurularak her bir nesnenin atık sınıfına ait güven skorları üretilmiş ve en yüksek olasılığa sahip sınıf tespit edilmiştir.

### III. DENEYSEL ÇALIŞMALAR

Çalışmanın bu bölümünde, önerilen derin öğrenme modellerinin eğitim süreçleri, kullanılan donanımsal ve yazılımsal altyapılar, hiperparametre optimizasyonları ve elde edilen sınıflandırma performansları üç temel aşamada detaylandırılmıştır.

#### A. Eğitim Parametreleri ve Değerlendirme Metrikleri

Modellerin eğitim süreci, bulut tabanlı bir geliştirme ortamında NVIDIA T4 grafik işlemci birimi (GPU) donanımı kullanılarak yüksek performanslı bir mimari üzerinde gerçekleştirilmiştir. Yazılım altyapısı olarak Python programlama dili ve TensorFlow/Keras derin öğrenme kütüphanelerinden faydalanılmıştır. Model eğitimleri, aşırı öğrenmeyi önlemek ve donanım kaynaklarını efektif kullanmak adına 15 döngü (epoch) ve 16 yığın boyutu (batch size) ile sınırlandırılmıştır. Öğrenme hızı (learning rate) temel eğitim aşamasında 0.001 olarak ayarlanmış, ince ayar (fine-tuning) aşamasında ise modelin atık dokularındaki hassas detayları daha iyi öğrenebilmesi için 0.00001 seviyesine düşürülmüştür. Ağırlık güncellemeleri ve ağırlık kaybı optimizasyonu için Adam algoritması tercih edilmiştir.

Modellerin başarısını bilimsel bir çerçevede değerlendirmek için Doğruluk, Kesinlik, Geri Çağırma ve F1-Skor metrikleri kullanılmıştır. Doğruluk, modelin doğru sınıflandırdığı toplam örneklerin tüm örneklerle oranını ifade eder. Kesinlik, modelin belirli bir atık sınıfı olarak tahmin ettiği örneklerin ne kadarının gerçekten o sınıfa ait olduğunu gösterir. Geri Çağırma ise gerçekte o sınıfa ait olan atıkların ne kadarının model tarafından doğru tespit edildiğinin bir ölçütüdür. F1-Skor değeri ise bu metriklerin harmonik ortalamasını alarak, özellikle dengesiz sınıf dağılımlarına sahip veri setlerinde modelin kararlılığını ölçen en kapsamlı değerlendirme kriteridir.

#### B. Karşılaştırmalı Model Sonuçları

Test verileri üzerinde yapılan kapsamlı değerlendirmeler sonucunda, düşük parametre sayısı ile hızlı işlem yapabilen temel MobileNetV2 [5] mimarisi ile kapasitesi ve özellik çıkarım derinliği artırılmış EfficientNetB3 [6] mimarisinin sınıflandırma başarıları Tablo 1'de karşılaştırmalı olarak sunulmuştur.

Tablo 1. MobileNetV2 ve EfficientNetB3 Modellerinin Atık Tespiti Sonuçları


| Model          | Geri Çağırma | Kesinlik | Doğruluk |
|----------------|--------------|----------|----------|
| MobileNetV2    | 0.760        | 0.750    | 0.760    |
| EfficientNetB3 | 0.950        | 0.950    | 0.952    |

Elde edilen bulgular, atıkların şeffaflık, yansıma ve ezilmiş dokular gibi heterojen özelliklerini analiz etmede EfficientNetB3 mimarisinin belirgin bir üstünlüğe sahip olduğunu göstermektedir. %76.0 seviyesinde kalan temel modele kıyasla %95.2 genel doğruluk oranına ulaşılması, endüstriyel geri dönüşüm hatları için kritik bir başarıdır.



#### C. Model Kararlılığı ve Açıklanabilirlik

Karşılaştırmalı analiz sonucunda en yüksek performansı gösteren EfficientNetB3 modelinin kararlılığı (stability), eğitim ve doğrulama kayıp grafikleri (Şekil 2) üzerinden incelenmiştir. Eğitim ve doğrulama eğrilerinin birbirini uyumlu bir şekilde ve dar bir varyans aralığında takip etmesi, uygulanan güvenli ince ayar (safe fine-tuning) stratejisinin modelin ezberleme yapmasını tamamen engellediğini kanıtlamaktadır.

Ayrıca elde edilen karmaşıklık matrisinde (Şekil 1) diyagonal eksenindeki yüksek yoğunlaşma, ayrıştırma gücünün sınıflar arasına dengeli dağıldığını göstermektedir. Özellikle kağıt ve cam sınıflarında mükemmele yakın bir ayrıştırma başarısı yakalanmıştır. Modelin açıklanabilirliği kapsamında, derin sinir ağlarının "kara kutu" yapısını şeffaflaştırmak büyük önem taşımaktadır. Bu doğrultuda, sonraki aşamalar için Grad-CAM [7] gibi gradyan tabanlı görselleştirme algoritmalarının sisteme entegrasyonu planlanmış olup, modelin atık tespiti yaparken görüntünün hangi bölgelerine, piksellerine ve doku özelliklerine odaklandığının analizi hedeflenmiştir.



Şekil 1. EfficientNetB3 Modeline Ait Karmaşıklık Matrisi



Şekil 2. Eğitim ve Doğrulama Grafikleri

#### IV. SONUÇ VE GELECEK ÇALIŞMALAR

##### A. Sonuç

Bu çalışmada, çevresel sürdürülebilirlik açısından büyük önem taşıyan atıkların otomatik ayrıştırılması problemi için derin öğrenme tabanlı bir otomasyon çözümü sunulmuştur. Sınıflandırma performansını optimize etmek amacıyla, hafif sıklet MobileNetV2 mimarisi ile başlanan süreç, daha yüksek özellik çıkarım kapasitesine sahip EfficientNetB3 mimarisine geçiş yapılarak tamamlanmıştır. Eğitim aşamasında uygulanan toplu normalizasyon katmanlarının dondurulduğu güvenli ince ayar (safe fine-tuning) stratejisi sayesinde, modelin yıkıcı unutma problemi engellenmiş ve %95.2 gibi endüstriyel standartlarda uygulanabilir, yüksek bir genel doğruluk oranına ulaşılmıştır.

##### B. Gelecek Çalışmalar

Bu çalışma kapsamında sınıflandırma başarısına odaklanıldığı için modelin karar mekanizmalarının görselleştirilmesi aşaması sonraya bırakılmıştır. Gelecek çalışmalarda, derin sinir ağlarının "kara kutu" yapısını şeffaflaştırmak amacıyla Grad-CAM gibi Açıklanabilir Yapay Zeka (XAI) algoritmalarının sisteme entegre edilmesi planlanmaktadır. Ayrıca, geliştirilen bu yazılım mimarisinin, farklı aydınlatma koşullarında zenginleştirilmiş bir veri seti ile eğitilerek, gerçek zamanlı çalışan bir konveyör bant sistemi ve donanımsal bir robotik kol ile entegre edilmesi; böylece uçtan uca otonom bir geri dönüşüm istasyonuna dönüştürülmesi hedeflenmektedir.

## V. KAYNAKALAR

- [1] S. Bircanoglu, P. Arica, H. Bilen, and C. Dag, "RecycleNet: Intelligent Waste Sorting Using Deep Neural Networks," 2018 Innovations in Intelligent Systems and Applications (INISTA), 2018, pp. 1-7.
- [2] Y. Zheng, "Garbage classification system based on improved YOLOv5," 2021 IEEE International Conference on Electronic Technology, Communication and Information (ICETCI), 2021, pp. 842-845.
- [3] M. L. Liu and B. He, "Application of Deep Learning in Garbage Classification," 2020 International Conference on Computer Vision, Image and Deep Learning (CVIDL), 2020, pp. 107-111.
- [4] Garbage Classification Dataset, Kaggle. [Online]. Available:  
<https://www.kaggle.com/asdasdasdasdas/garbage-classification>.
- [5] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L. Chen, "MobileNetV2: Inverted Residuals and Linear Bottlenecks," in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2018, pp. 4510-4520.
- [6] M. Tan and Q. Le, "EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks," in International Conference on Machine Learning (ICML), 2019, pp. 6105-6114.
- [7] R. R. Selvaraju et al., "Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization," in IEEE International Conference on Computer Vision (ICCV), 2017, pp. 618-626.